UNIVERSIDAD AUTÓNOMA DE SANTO DOMINGO · MAESTRÍA EN CIENCIAS DE DATOS E INTELIGENCIA ARTIFICIAL

Motor recomendador con MovieLens

Mandato · Ejercicio 05 · Informe de entrega

Asignatura	INF-8239 Ciencia de Datos II
Unidad	03 · Sistemas recomendadores y modelos generativos
Código	U03.E05
Estudiante	Alexis De La Cruz · Matrícula 100805370
Fecha	19 de octubre de 2026
Entorno	Windows 11 · Intel Core i9-13980HX · RAM 16 GB · Python 3.12.12 · scikit-learn 1.9.1 · NVIDIA RTX 4070 Laptop, 8 GB

1. Repositorio

Enlace: https://github.com/delaxis1/INF8239_U03_Recomendadores

Construido sobre el proyecto base LAB08-LAB09 del docente Edwin Ramón José Nolasco. El notebook descarga y verifica MovieLens, compara siete configuraciones y genera las métricas. Dataset Card, System Card y 19 pruebas automatizadas acompañan el repositorio privado.

2. Datos y partición reproducible

Conjunto	MovieLens Latest Small · 100,836 calificaciones · 610 usuarios · 9,742 películas
Fuente	GroupLens. Términos del README original; descarga reproducible sin redistribuir los datos.
Partición	80,669 entrenamiento · 10,083 validación · 10,084 prueba, mediante cortes temporales globales.
Auditoría	Sin nulos, claves huérfanas ni interacciones usuario/película duplicadas.
Trazabilidad	696d65a3dfceac7c45750ad32df2c259311949efec81f0f144fdfb91ebc9e436
Candidatos	Películas calificadas antes del corte; excluir vistas. Los relevantes fuera del catálogo cuentan como fallos.

3. Protocolo y elección del sistema

Se comparan conteo, popularidad suavizada, contenido por géneros, MF con 10/20 factores e híbridos con peso colaborativo α=0.25/0.75. MF usa 12 épocas y semillas 42, 7 y 2026. Relevante significa ≥4 estrellas; las listas tienen diez títulos.

El corte global conserva juntos los timestamps iguales y evita incorporar valoraciones de otros usuarios posteriores al momento evaluado. Regla previa: entre los modelos a ≤0.005 del mejor NDCG de validación, preferir cobertura y luego menor tiempo de ajuste.

Elección fijada antes de prueba: Conteo, con NDCG de validación 0.2887. Después se reajusta con entrenamiento y validación. El resultado final no cambia esa decisión.

4. Resultados de prueba

Configuración	NDCG@10	Hit@10	P@10	R@10	Cobertura	Ajuste(s)
Contenido (géneros)	0.2123	0.569	0.178	0.046	1.5%	0.06
Conteo	0.2576	0.625	0.226	0.061	0.9%	0.06
Híbrido · α=0.25	0.2262	0.625	0.190	0.049	2.0%	7.62
Híbrido · α=0.75	0.2466	0.704	0.207	0.056	1.6%	7.62
MF · 10 factores	0.2328	0.662	0.195	0.054	1.3%	8.47
MF · 20 factores	0.2352	0.681	0.199	0.055	1.5%	7.62
Popularidad suavizada	0.2434	0.653	0.204	0.056	0.5%	0.06

Métricas de ranking sobre 72 usuarios con positivos; 2 sin positivos se cuentan aparte. Usuarios de prueba: 74; nuevos sin historial: 47; relevantes fuera del catálogo: 652 (cuentan como fallos). Cobertura se calcula sobre las listas de todos los usuarios y el catálogo disponible.

5. Relevancia y cobertura del catálogo

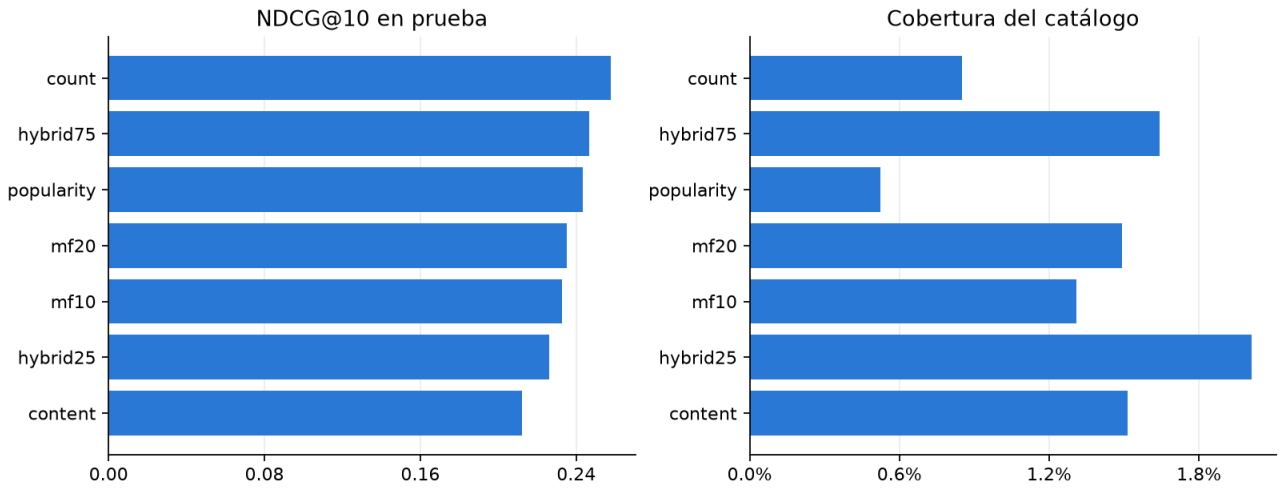


Figura 1. Ranking y amplitud del catálogo. Candidatos comunes para todos los métodos. La variación entre semillas no constituye intervalo de confianza; los controles deterministas se repiten sin aleatoriedad.

RMSE del componente MF20: 1.0601; MF10: 1.0605. En pares desconocidos se usa media por ítem/global. RMSE no evalúa directamente el orden Top-10 y, en híbridos, corresponde a su componente MF.

Los tiempos son medianas: preparación compartida más ajuste MF cuando aplica; latencia es media por usuario en lote. Tamaño del artefacto comprimido se informa en las tablas del repositorio y no equivale a memoria RAM máxima.

Duración total del experimento: 1.6 minutos. Pico de memoria del kernel: 290.1 MiB (peak working set de Windows desde la creación del proceso; no RAM de todo el sistema).

6. Costo y frontera de Pareto

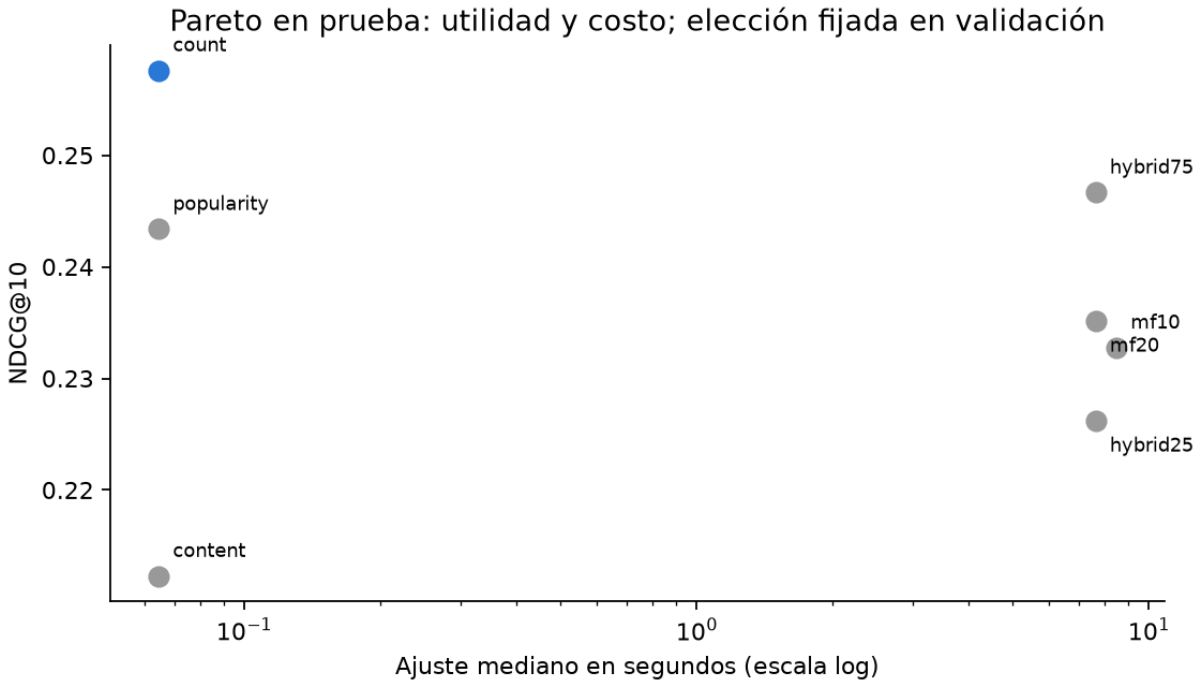


Figura 2. Frontera de utilidad/costo de ajuste en prueba (descriptiva). Azul: no dominados bajo ambos criterios; gris: dominados. La elección permanece fijada con validación.

7. Perfiles de usuario y límites

Perfil	Historial	Primeras recomendaciones
amplio	2581	Shining, The (1980); Ace Ventura: When Nature Calls (1995); Addams Family Values (1993)
pequeño	15	Forrest Gump (1994); Shawshank Redemption, The (1994); Pulp Fiction (1994)
nuevo	0	Forrest Gump (1994); Shawshank Redemption, The (1994); Pulp Fiction (1994)

En usuarios con historial, NDCG del híbrido α0.75=0.1132, frente a 0.0889 del conteo. El ranking global está influido por el alto número de usuarios nuevos; no permite afirmar que el conteo sea superior en todos los segmentos.

El perfil nuevo es sintético y usa el respaldo de popularidad del método elegido; los otros son extremos de historial observado. La aplicación permite explorar Top-10 por usuario y similitud por título. Contenido usa géneros y puede sobreespecializar las listas. Sin exposición registrada ni datos demográficos, no se demuestra satisfacción ni equidad entre grupos.

Diversidad media del sistema elegido: 0.787 (distancia Jaccard entre géneros); novedad: 8.683 bits, aproximada por frecuencia inversa de calificación. No son valoraciones humanas.

8. Conclusión

En esta práctica quise comprobar si un recomendador más complejo realmente ayudaba a ordenar mejor las películas. Partí de MovieLens y comparé siete configuraciones, desde un conteo de popularidad hasta factorización e híbridos. Lo primero que tuve que aclarar fue qué significaba acertar: consideré relevante una película con cuatro estrellas o más y evalué listas de diez títulos. Predecir una calificación cercana a la real y recomendar una película que aparezca entre los intereses futuros son tareas relacionadas, pero no equivalentes.

Para evitar usar información del futuro, separé las interacciones por fecha en entrenamiento, validación y prueba. Esta decisión hizo más exigente la evaluación: de los 74 usuarios de prueba, 47 todavía no tenían historial al momento del ajuste final. A esos usuarios les ofrecí conteo de popularidad. Por eso no puedo interpretar sus listas como recomendaciones personalizadas. También conservé los positivos que estaban fuera del catálogo como fallos, porque eliminarlos habría dado una impresión demasiado favorable del sistema.

Con la regla fijada antes de revisar prueba, seleccioné Conteo. En validación alcanzó NDCG@10 de 0.2887; en prueba obtuvo 0.2576 y cobertura de 0.9%. La popularidad suavizada obtuvo 0.2434. El mayor NDCG observado en prueba correspondió a Conteo, con 0.2576, pero ese resultado posterior no se utilizó para cambiar la elección. Para mí, separar ambas decisiones es una parte importante del ejercicio: de lo contrario estaría ajustando el sistema a la misma prueba con la que pretendo justificarlo.

Entre los usuarios con historial, el híbrido α0.75 obtuvo NDCG 0.1132 frente a 0.0889 del conteo. Ese contraste me hizo bajar las expectativas de encontrar un ganador universal. La revisión de los perfiles me ayudó a entender los límites de cada enfoque. Con pocos datos del usuario, el respaldo de popularidad es fácil de explicar, aunque repite títulos. El contenido aprovecha géneros y puede ampliar el catálogo recomendado, pero conocer los géneros no significa conocer toda la película. La factorización incorpora patrones compartidos y añade tiempo de ajuste; mezclarla con contenido tampoco garantiza una mejora. La cobertura y la diversidad sirven para describir esas diferencias, sin reemplazar la relevancia.

Me quedo con un procedimiento que puedo volver a ejecutar y revisar: descarga con huella, cortes guardados, candidatos comunes, tres semillas y pruebas de los casos delicados. Los resultados corresponden a este conjunto histórico y a este protocolo; no demuestran cómo responderían personas reales en una aplicación. Antes de llevarlo a producción comprobaría el arranque en frío, contrastaría otras ventanas temporales y mediría utilidad con usuarios, manteniendo separada una evaluación final.

9. Referencias y nota del autor

Harper, F. M., & Konstan, J. A. (2015). The MovieLens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems, 5*(4), artículo 19. https://doi.org/10.1145/2827872

GroupLens. (s. f.). *MovieLens Latest Datasets*. grouplens.org/datasets/movielens/latest/. Nolasco, E. R. J. (s. f.). *Manual y proyecto base LAB08–LAB09, INF-8239* [Material de curso]. UASD Virtual.

Se utilizó Codex (OpenAI) como apoyo de programación, documentación y verificación. El código base del docente y las correcciones se identifican en Git; prompts y controles están en AI_USE_DECLARATION.md. La conclusión es un borrador sujeto a revisión personal antes de la entrega.