Unidad 03 · Ejercicio 05

Recomendación Top-10 con MovieLens

Alexis De La Cruz · Matrícula 100805370
INF-8239 · Ciencia de Datos II · UASD
Docente: Edwin Ramón José Nolasco

Repositorio privado: https://github.com/delaxis1/INF8239_U03_Recomendadores

Datos y pregunta

¿Qué combinación de popularidad, contenido y factorización logra un ranking útil sin un costo de ajuste innecesario? MovieLens contiene 100,836 calificaciones de 610 usuarios y 9,742 películas. Se usan calificaciones, fecha y géneros; no se introducen atributos demográficos.

Fuente: GroupLens, MovieLens Latest Small. Se respetan los términos del README original y se entrega descarga reproducible, sin redistribuir los datos. Auditoría sin nulos, claves huérfanas ni interacciones usuario/película duplicadas.

SHA-256 del ZIP: 696d65a3dfceac7c45750ad32df2c259311949efec81f0f144fdfb91ebc9e436

Protocolo y selección

Corte temporal global: 80,669 filas para ajuste, 10,083 para validación y 10,084 para prueba. Los timestamps iguales quedan juntos. Se difiere del leave-last por usuario de la base para impedir que entren calificaciones de otros usuarios posteriores al corte evaluado. El catálogo contiene solo películas ya calificadas al corte; se excluyen las vistas.

Relevante: ≥4 estrellas. Listas de diez títulos. MF con 10/20 factores, 12 épocas y semillas 42, 7 y 2026. Híbridos con peso colaborativo $\alpha=0.25/0.75$ y scores normalizados sobre el mismo catálogo. Regla previa: a ≤ 0.005 del mejor NDCG de validación, preferir cobertura y luego menor ajuste.

Elección registrada antes de prueba: **Conteo** (NDCG validación 0.2887). Después se reajusta con entrenamiento + validación. No se cambia la elección por la tabla final.

Entorno y reproducción

Python 3.12.12; scikit-learn 1.9.1; uv.lock. Intel Core i9-13980HX; RAM 16 GB; NVIDIA RTX 4070 Laptop, 8 GB; Windows 11. Duración observada: 1.6 min. Pico de memoria del kernel: 290.1 MiB (peak working set de Windows desde la creación del proceso; no RAM de todo el sistema). Notebook y 19 pruebas automatizadas acompañan el repositorio.

Resultados de prueba · promedio de tres semillas

Configuración	NDCG@10	Hit@10	P@10	R@10	Cobertura	Ajuste(s)
Contenido (géneros)	0.2123	0.569	0.178	0.046	1.5%	0.06
Conteo	0.2576	0.625	0.226	0.061	0.9%	0.06
Híbrido · α=0.25	0.2262	0.625	0.190	0.049	2.0%	7.62
Híbrido · α=0.75	0.2466	0.704	0.207	0.056	1.6%	7.62
MF · 10 factores	0.2328	0.662	0.195	0.054	1.3%	8.47
MF · 20 factores	0.2352	0.681	0.199	0.055	1.5%	7.62
Popularidad suavizada	0.2434	0.653	0.204	0.056	0.5%	0.06

Métricas de ranking sobre 72 usuarios con positivos; 2 sin positivos se cuentan aparte. Usuarios de prueba: 74; nuevos sin historial: 47; relevantes fuera del catálogo: 652 (cuentan como fallos). Cobertura se calcula sobre las listas de todos los usuarios y el catálogo disponible.

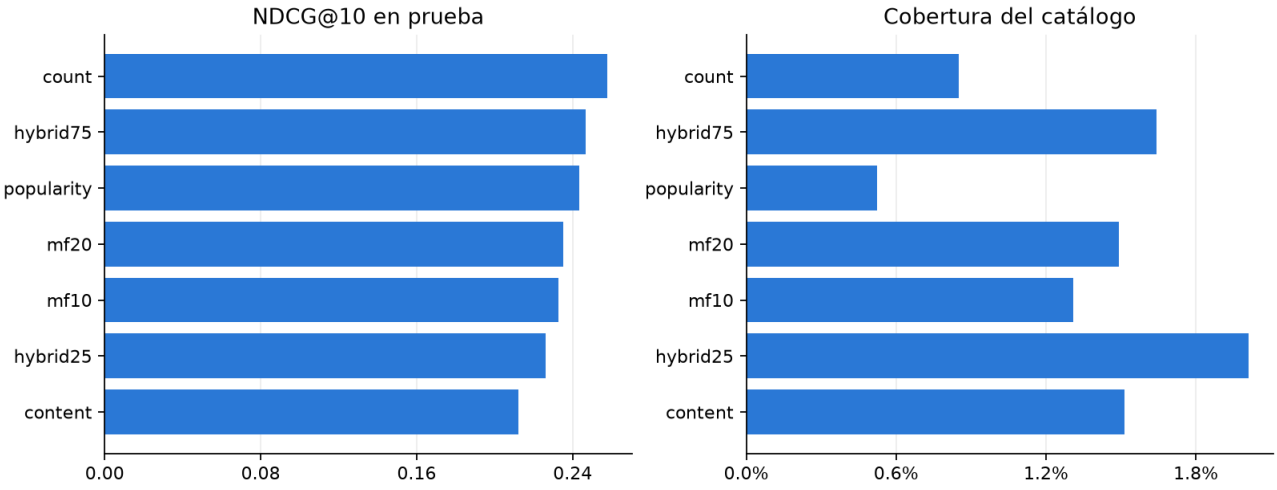


Figura 1. Ranking y amplitud del catálogo. Candidatos comunes para todos los métodos. La variación entre semillas no constituye intervalo de confianza; los controles deterministas se repiten sin aleatoriedad.

RMSE del componente MF20: 1.0601; MF10: 1.0605. En pares desconocidos se usa media por ítem/global. RMSE no evalúa directamente el orden Top-10 y, en híbridos, corresponde a su componente MF.

Los tiempos son medianas: preparación compartida más ajuste MF cuando aplica; latencia es media por usuario en lote. Tamaño del artefacto comprimido se informa en las tablas del repositorio y no equivale a memoria RAM máxima.

Costo, cobertura y límites

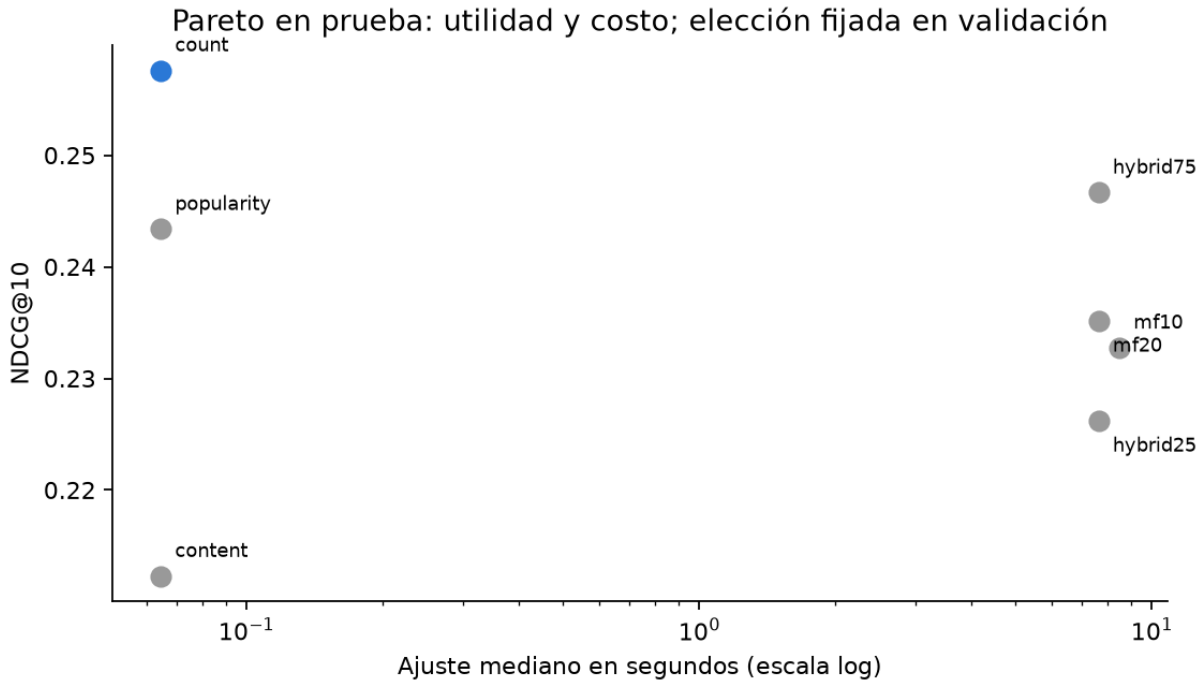


Figura 2. Frontera de utilidad/costo de ajuste en prueba (descriptiva). Azul: no dominados bajo ambos criterios; gris: dominados. La elección permanece fijada con validación.

Perfil	Historial	Primeras recomendaciones
amplio	2581	Shining, The (1980); Ace Ventura: When Nature Calls (1995); Addams Family Values (1993)
pequeño	15	Forrest Gump (1994); Shawshank Redemption, The (1994); Pulp Fiction (1994)
nuevo	0	Forrest Gump (1994); Shawshank Redemption, The (1994); Pulp Fiction (1994)

En usuarios con historial, NDCG del híbrido α0.75=0.1132, frente a 0.0889 del conteo. El ranking global está influido por el alto número de usuarios nuevos; no permite afirmar que el conteo sea superior en todos los segmentos.

El perfil nuevo es sintético y usa el respaldo de popularidad del método elegido; los otros son extremos de historial observado. La aplicación permite explorar Top-10 por usuario y similitud por título. Contenido usa géneros y puede sobreespecializar las listas. Sin exposición registrada ni datos demográficos, no se demuestra satisfacción ni equidad entre grupos.

Diversidad media del sistema elegido: 0.787 (distancia Jaccard entre géneros); novedad: 8.683 bits, aproximada por frecuencia inversa de calificación. No son valoraciones humanas.

Conclusión

En esta práctica quise comprobar si un recomendador más complejo realmente ayudaba a ordenar mejor las películas. Partí de MovieLens y comparé siete configuraciones, desde un conteo de popularidad hasta factorización e híbridos. Lo primero que tuve que aclarar fue qué significaba acertar: consideré relevante una película con cuatro estrellas o más y evalué listas de diez títulos. Predecir una calificación cercana a la real y recomendar una película que aparezca entre los intereses futuros son tareas relacionadas, pero no equivalentes.

Para evitar usar información del futuro, separé las interacciones por fecha en entrenamiento, validación y prueba. Esta decisión hizo más exigente la evaluación: de los 74 usuarios de prueba, 47 todavía no tenían historial al momento del ajuste final. A esos usuarios les ofrecí conteo de popularidad. Por eso no puedo interpretar sus listas como recomendaciones personalizadas. También conservé los positivos que estaban fuera del catálogo como fallos, porque eliminarlos habría dado una impresión demasiado favorable del sistema.

Con la regla fijada antes de revisar prueba, seleccioné Conteo. En validación alcanzó NDCG@10 de 0.2887; en prueba obtuvo 0.2576 y cobertura de 0.9%. La popularidad suavizada obtuvo 0.2434. El mayor NDCG observado en prueba correspondió a Conteo, con 0.2576, pero ese resultado posterior no se utilizó para cambiar la elección. Para mí, separar ambas decisiones es una parte importante del ejercicio: de lo contrario estaría ajustando el sistema a la misma prueba con la que pretendo justificarlo.

Entre los usuarios con historial, el híbrido α0.75 obtuvo NDCG 0.1132 frente a 0.0889 del conteo. Ese contraste me hizo bajar las expectativas de encontrar un ganador universal. La revisión de los perfiles me ayudó a entender los límites de cada enfoque. Con pocos datos del usuario, el respaldo de popularidad es fácil de explicar, aunque repite títulos. El contenido aprovecha géneros y puede ampliar el catálogo recomendado, pero conocer los géneros no significa conocer toda la película. La factorización incorpora patrones compartidos y añade tiempo de ajuste; mezclarla con contenido tampoco garantiza una mejora. La cobertura y la diversidad sirven para describir esas diferencias, sin reemplazar la relevancia.

Me quedo con un procedimiento que puedo volver a ejecutar y revisar: descarga con huella, cortes guardados, candidatos comunes, tres semillas y pruebas de los casos delicados. Los resultados corresponden a este conjunto histórico y a este protocolo; no demuestran cómo responderían personas reales en una aplicación. Antes de llevarlo a producción comprobaría el arranque en frío, contrastaría otras ventanas temporales y mediría utilidad con usuarios, manteniendo separada una evaluación final.

Referencias y nota del autor

Harper, F. M., & Konstan, J. A. (2015). The MovieLens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems, 5*(4), artículo 19. https://doi.org/10.1145/2827872

GroupLens. (s. f.). *MovieLens Latest Datasets*. grouplens.org/datasets/movielens/latest/. Nolasco, E. R. J. (s. f.). *Manual y proyecto base LAB08–LAB09, INF-8239* [Material de curso]. UASD Virtual.

Se utilizó Codex (OpenAI) como apoyo de programación, documentación y verificación. El código base del docente y las correcciones se identifican en Git; prompts y controles están en AI_USE_DECLARATION.md. La conclusión es un borrador sujeto a revisión personal antes de la entrega.